

AI트랙미니프로젝트1차 - 5반 15조

고객 만족도 예측을 통한 서비스 개선

조장: 최현준

발표자: 오승헌

PPT 제작자: 김채린, 강민주

서기: 황민서, 김경민

검토 담당자: 이채은

타임키퍼: 김다애



목차

Analysis

- 데이터 분석 및 목적
- 데이터 현황 및 탐색적 분석
- 주요 영향 변수 도출
- 데이터 전처리 과정

Modeling

- Base Model 설계 및 선정
- 최종 모델 파이프라인 설계 방향
- 최종 모델 파이프라인 구성
- 모델 성능 비교 및 결과 분석

Conclusion

- 팀 논의 결과 및 회고



데이터 분석 및 목적

“설문 만족도와 실제 고객 경험 간 괴리”

[key question]

- 설문 결과는 좋은데 실제 고객 불만이 발생하는가?
- 현재 분석 시스템에 문제가 있는 것?
- 고객 불만을 미리 예측할 수 있는 방법은 없는가?

높은 설문 만족도



실제 고객 불만 발생



측정 시스템 신뢰도 의문



예측 모델 기반 개선 필요

데이터 현황

data.csv → 데이터 타입 통일X


data.info()

```
<class 'pandas.core.frame.DataFrame'>  
RangeIndex: 19278 entries, 0 to 19277  
Data columns (total 25 columns):
```

#	Column	Non-Null Count	Dtype
0	Unnamed: 0	19278 non-null	int64
1	ID	19278 non-null	int64
2	Gender	19278 non-null	object
3	Customer Type	19278 non-null	object
4	Age	18626 non-null	float64
5	Type of Travel	19278 non-null	object
6	Class	19278 non-null	object
7	Flight Distance	19278 non-null	int64
8	Inflight wifi service	18640 non-null	float64
9	Departure/Arrival time convenient	19278 non-null	int64
10	Ease of Online booking	19278 non-null	int64
11	Gate location	19278 non-null	int64
12	Food and drink	18893 non-null	float64
13	Online boarding	19278 non-null	int64
14	Seat comfort	18791 non-null	float64
15	Inflight entertainment	19278 non-null	int64
16	On-board service	19278 non-null	int64
17	Leg room service	19278 non-null	int64
18	Baggage handling	19278 non-null	int64
19	Checkin service	19278 non-null	int64
20	Inflight service	19278 non-null	int64
21	Cleanliness	19278 non-null	int64
22	Departure Delay in Minutes	19278 non-null	int64
23	Arrival Delay in Minutes	19224 non-null	float64
24	Satisfaction	19278 non-null	object

dtypes: float64(5), int64(15), object(5)




←타겟 설정



1일차

데이터 불균형 有

범주형 데이터 전처리 필요




중요 변수 확인

고객님들의 불만을 발생 시킬 수 있는 가장 영향력 있는 요인들을 파악하였습니다.

예측

- Type of Travel
- Flight Distance
- Departure/Arrival time convenient
- Seat comfort
- Departure/Arrival Delay in Minutes

실제(RandomForest)



고객 만족도는 '기내 와이파이 만족도'와 '온라인 탑승 수속 만족도', 그리고 '여행 유형'에 가장 크게 영향을 받았습니다.

기내 와이파이 품질의 서비스 향상과, 온라인 탑승 수속의 편의성 증대를 통해 고객의 만족도를 높일 수 있을 것입니다.

데이터 전처리

```
# 1. 결측치 처리
num_cols = data.select_dtypes(include=['number']).columns # 수치형 변수 선택

# 결측치 → 중앙값
for col in num_cols:
    median_val = data[col].median()
    data[col].fillna(median_val, inplace=True)

cat_cols = data.select_dtypes(include=['object', 'category']).columns # 범주형 변수 선택

# 결측치 → 최빈값
for col in cat_cols:
    mode_v = data[col].mode() # mode()는 Series를 반환합니다.
    if not mode_v.empty:
        data[col].fillna(mode_v[0], inplace=True) # mode_v[0]를 사용하여 실제 최빈값을 채웁니다.
```

```
# 2. 값 변경

# Target -> Satisfaction 값을 1과 0으로
data['Satisfaction'] = data['Satisfaction'].map({'Satisfied': 1, 'Neutral or Dissatisfied': 0})

# 3. 변수 제거
data.drop(columns=['Unnamed: 0', 'ID'], axis=1, inplace=True)
```

1. 결측치 처리

- 수치형 변수: 중앙값으로 대체
- 범주형 변수: 최빈값으로 대체

→ 데이터 손실 없이 안정적인 학습 가능

2~3. Satisfaction 값 변경 및 불필요한 변수 제거

- Satisfaction Column의 Value 값이 문자열
=> map을 사용하여 1, 0으로 맵핑
- Unnamed: 0, ID 등 불필요한 열 제거

데이터 전처리

```
# 4. 라벨 인코딩
# 문자열 변수 리스트로 선언
cat_cols = ['Gender', 'Customer Type', 'Type of Travel', 'Class']

# 라벨 인코딩
for col in cat_cols:
    encoder = LabelEncoder()
    data[col] = encoder.fit_transform(data[col])
```

```
# 5. 가변수화

categories = [0, 1, 2, 3, 4, 5] # 설문 범주 정의

# 가변수화 대상 변수
dumm_cols = ['Inflight wifi service', 'Departure/Arrival time convenient', 'Ease of Online booking', 'Gate location',
             'Food and drink', 'Online boarding', 'Seat comfort', 'Inflight entertainment', 'On-board service',
             'Leg room service', 'Baggage handling', 'Checkin service', 'Inflight service', 'Cleanliness']

# Category 형 변수로 변환
for col in dumm_cols:
    data[col] = pd.Categorical(data[col], categories=categories)

# 가변수화
data = pd.get_dummies(data, columns=dumm_cols, drop_first=True, dtype=int)
```

```
# 6. x, y 분리
target = 'Satisfaction'
x = data.drop(target, axis=1)
y = data.loc[:, target]

# 7. 스케일링
x = scaler.transform(x)

# 반환
return x, y
```

6~7. 데이터 분리 및 스케일링

Satisfaction 기준으로 x, y 데이터 분리 후,
불러온 scaler를 사용하여 스케일링 진행

4. 라벨 인코딩

범주형 변수(Gender, Customer Type 등)를 숫자 형태로 변환

→ 모델이 데이터를 처리할 수 있도록 변환

5. 가변수화

- 설문 점수(0~5)를 이진 변수로 분리
- 각 점수를 독립적인 feature로 표현
- → 모델이 범주 간 순서 없이 관계를 학습하도록 함

1일차 토론 후, 15조 베이스 모델

방법 1:클래스 가중치 - 현준

	정밀도	재현율
0	0.69	0.90
1	0.99	0.96

→ 0(불만족)의 재현율을 높이는 데에만 치중한 결과
정작, 만족한 사람도 불만족으로 판단할 확률 높음


방법 2:L2 규제 - 채은

	정밀도	재현율
0	0.87	0.81
1	0.98	0.99

→ L2 규제를 통해 가중치에 대한 편견 최대한 제거
타겟변수 비율에 대해 완만한 결과 도출

⇒ 위 두 모델을 합쳐 새로운 데이터에 일반화를 하고자 두 모델을 합쳐 실험 진행

최종 모델



L2 Regularization (on Dense Layers)



Model1 데이터 재학습


구분	Precision	Recall	F1-Score	Support
Class 0	0.92	0.92	0.92	191
Class 1	0.91	0.91	0.91	159
Accuracy			0.91	350
Macro Avg	0.91	0.91	0.91	350
Weighted Avg	0.91	0.91	0.91	350

Model2 데이터 이어학습

구분	Precision	Recall	F1-Score	Support
Class 0	0.91	0.81	0.86	191
Class 1	0.8	0.9	0.85	159
Accuracy			0.85	350
Macro Avg	0.85	0.86	0.85	350
Weighted Avg	0.86	0.85	0.85	350

Model3

Learning Curve



구분	Precision	Recall	F1-Score	Support
Class 0	0.92	0.94	0.93	191
Class 1	0.93	0.91	0.92	159
Accuracy			0.93	350
Macro Avg	0.93	0.92	0.92	350
Weighted Avg	0.93	0.93	0.93	350

[주요 논의 사항]

모델 안에서 hyperparameter를 조정하는 것은 시간상 한계가 있을 것.
=> 적절한 Threshold를 Grid Search를 통해 찾아서 Recall 값을 높일 수 있지 않을까?

[Fine-Tuning]

- **model 1** base
- **5 layer freeze**
- **new hidden layer** : Dense(8, activation='relu'), dropout(0.3)
- **Threshold Grid Search**
: 0.63 (recall이 최소한 0.9를 넘는 것 중 precision이 최대인 것)

고객 관리 전략 제안

분석 결과를 기반으로 한 타겟 마케팅 토의 결과

**불만족 확률이 높은 고객군에게 선제적 보상(마일리지 등) 제공
점수가 낮게 나온 특정 서비스(예: 기내 와이파이) 집중 투자**

불만족 비율이 높은 항목에 대한 집중 개선안 마련 필요

해당 항목의 전체적인 품질을 끌어올려 높은 점수를 받는 것으로 전체 만족도에 대한 긍정적 비율 상승 기대 가능

팀 논의 결과 및 회고

"데이터는 거짓말을 하지 않지만, 해석하는 사람의 관점이 그 가치를 결정한다"

- 기술적 성장: 딥러닝 모델의 구조 설계뿐만 아니라, 전처리 파이프라인 구축을 통해 데이터 엔지니어링의 중요성을 깨달았습니다.
- 비즈니스 마인드: 데이터 분석은 단순히 코드를 짜는 것이 아니라, 기업의 문제를 해결하는 과정임을 배웠습니다. 특히 Recall 지표의 중요성을 이해하며 고객 중심의 사고방식을 갖게 되었습니다.
- 협업의 가치: 혼자였다면 정확도 수치에만 매몰됐겠지만, 팀원들과의 토론을 통해 '불균형 데이터 처리'와 '과적합 방지'라는 더 높은 수준의 분석 결과물을 도출할 수 있었습니다.

Thank You

